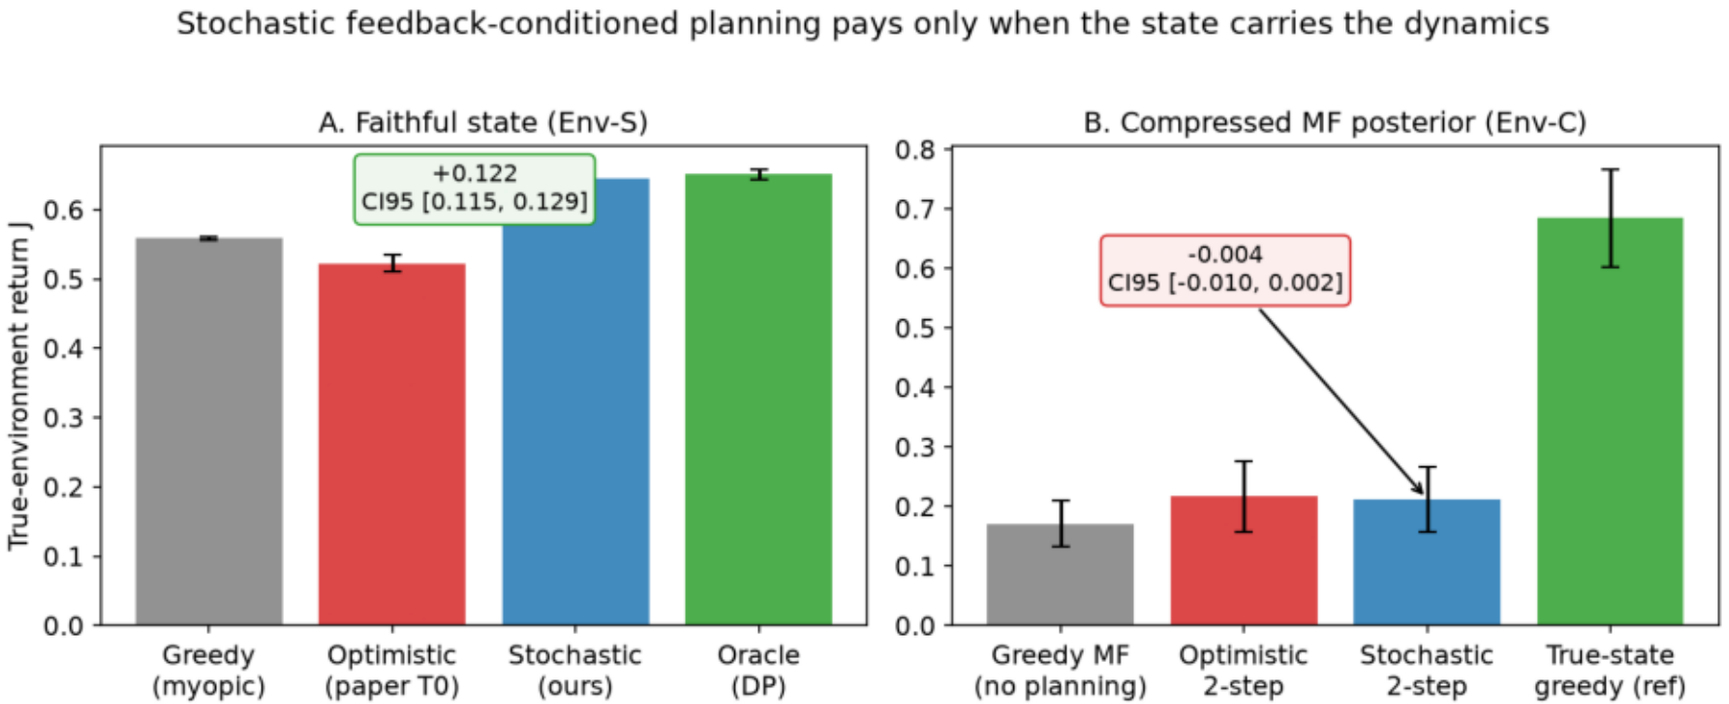
Когда планирование окупается: стохастические модели пользователя в рекомендациях

Цель: проверить, даёт ли моделирование стохастических реакций пользователя и обусловленных ими переходов состояния выигрыш в суммарной полезности J(π) по сравнению с оптимистичной моделью.



Ключевое сообщение: стохастическое планирование окупается только когда представление состояния несёт динамику — при честном состоянии оно достигает оракула (+0.122, CI95 [0.115, 0.129]), над сжатым MF-постериором — не отличается от оптимистичного (−0.004).

Обозначения: J(π) — ожидаемая суммарная полезность политики π в истинной среде; T0 — оптимистичный переход (принятие всегда); T1 — стохастическая модель отклика + точное взвешенное обновление; DP-оракул — точное решение методом обратной индукции.

Термины: оптимистичный переход; feedback-conditioned transition; контролируемая среда с известной динамикой; сжатое состояние (MF-постериор).

github.com/arinaromashkina/planning_over_MF_MDP · figures/main_figure.pdf