Однослайдовый доклад: когда окупается планирование в рекомендациях

Постановка (MF-MDP). Состояние $s = (P, u)$, $P = A^{-1}$; оптимистичный переход (принятие всегда):

$$P^+ = P - \frac{zz^\top}{1+\ell}, \quad u^+ = u + \frac{z(1-u^\top v)}{1+\ell}, \quad z = Pv,\ \ell = v^\top Pv.$$

Награда: $r(s,a) = \mathrm{sim}(u, v_a) + \eta/(1 + |\Delta s(a)|)$.

Стохастическая модель (наша). Отклик $y \sim p_\phi(y \mid s, a)$; переход, обусловленный откликом, — точное взвешенное обновление (α, β):

$$P^+ = P - \frac{\alpha zz^\top}{1+\alpha\ell}, \qquad u^+ = u + \frac{z(\beta - \alpha u^\top v)}{1+\alpha\ell}.$$

Планирование: $Q(s,a) = \mathbb{E}_y\big[r + \gamma(1-h)\,V(s')\big]$ (chance nodes).

Цель. Сравнить $J(\pi_{\text{stoch}})$ и $J(\pi_{\text{opt}})$ в контролируемых средах с известной динамикой и точным DP-оракулом; факторы: качество состояния, глубина, ошибка модели отклика.

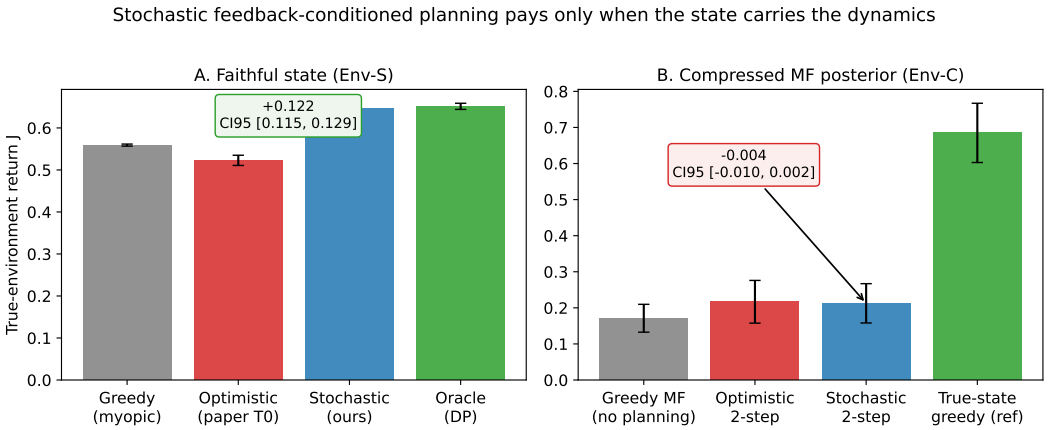


Рис. 1. Слева — честное состояние (Env-S); справа — сжатый MF-постериор (Env-C).

Ключевое сообщение: стохастическое планирование окупается только когда представление состояния несёт динамику: при честном состоянии оно достигает оракула ($+0.122$, CI95 $[0.115, 0.129]$), над сжатым MF-постериором — не отличается от оптимистичного (-0.004).

Обозначения: $J(\pi)$ — ожидаемая суммарная полезность политики π в истинной среде; T0 — оптимистичный переход; T1 — стохастическая модель отклика с точным взвешенным обновлением; DP-оракул — точное решение методом обратной индукции. **Термины:** оптимистичный переход; feedback-conditioned transition; контролируемая среда; сжатое состояние (MF-постериор).